# Pemanfaatan AI untuk **Pengamanan Media Sosial**

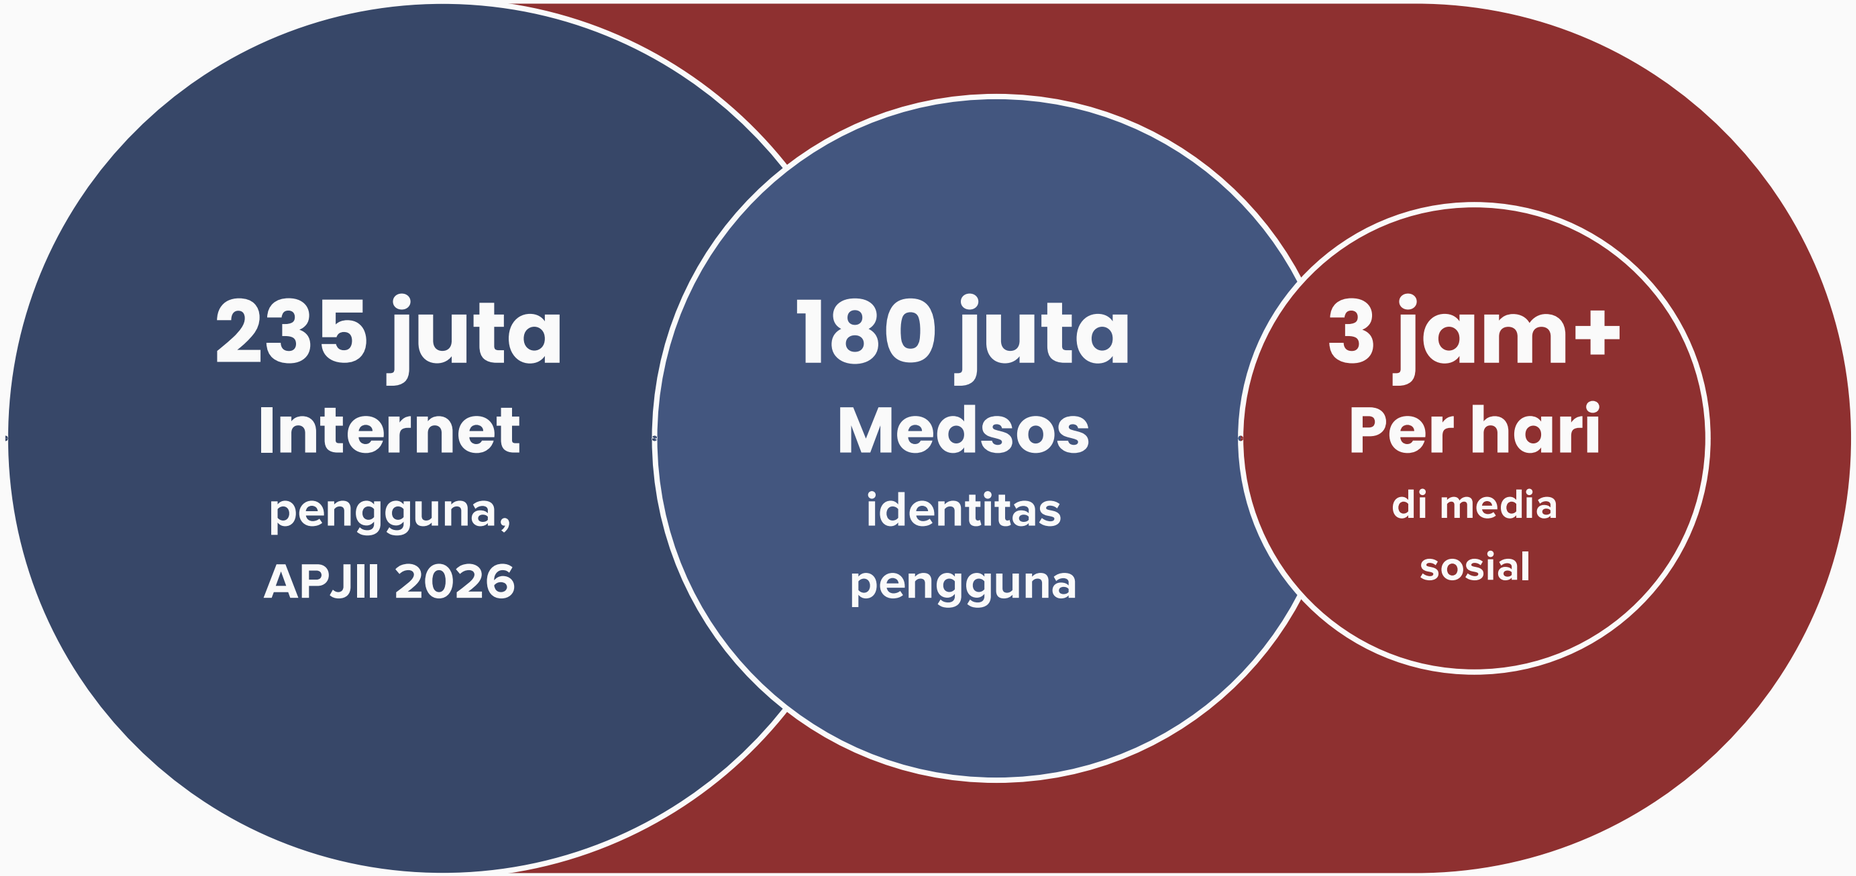
**Muhammad Okky Ibrohim, S.Mat., M.Kom., Ph.D.**

**Fakultas Ilmu Komputer, Universitas Indonesia**

# Outline

- Ujaran kebencian di media sosial
- Dari ruang digital ke dunia nyata
- Peran AI dalam pengamanan media sosial
- *Hate Speech Detection*
- Dari deteksi ke pencegahan
- Etika dan batasan
- *Try yourself!* Eksperimen langsung

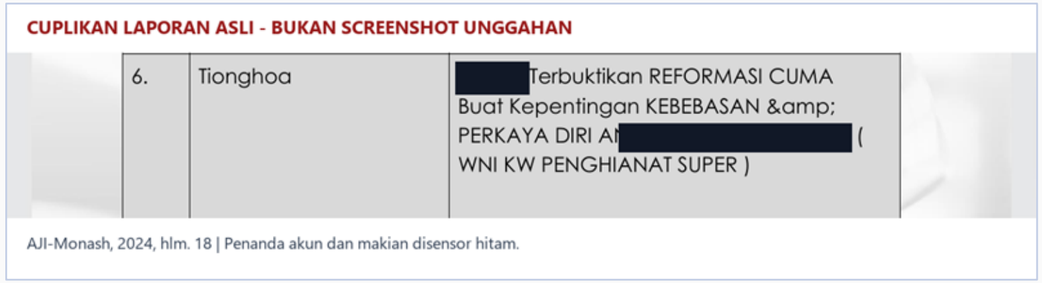
# Media sosial: ruang publik kita




*Sumber: APJII 2026 (survei Feb-Mar 2026, penetrasi 81,72%); We Are Social dan Meltwater, Digital 2026 (data Oktober 2025). Periode dan metode berbeda.*

# Wajah ujaran kebencian

## Etnis Tionghoa


CUPLIKAN LAPORAN ASLI - BUKAN SCREENSHOT UNGGAHAN

| | | |
|---|---|---|
| 6. | Tionghoa | [redacted]Terbuktikan REFORMASI CUMA Buat Kepentingan KEBEBASAN & PERKAYA DIRI A[redacted] ( WNI KW PENGHIANAT SUPER ) |

AJI-Monash, 2024, hlm. 18 | Penanda akun dan makian disensor hitam.

*Perendahan sebagai warga tidak setara, disertai makian (disensor). Laporan AJI-Monash, 2024.*

## Ras dan etnis: Papua




Rilis Polri, 22 Februari 2024 | Cuplikan judul; isi yang memuat identitas akun dikeluarkan.

*Konten SARA tentang Papua di TikTok; berkas perkara dinyatakan lengkap (P21), bukan vonis. Rilis Polri, 22 Februari 2024.*

## Agama

**Stereotip dan perendahan terhadap kelompok Syiah tercatat dalam contoh pemantauan ujaran kebencian Pemilu 2024.**

*Laporan AJI-Monash, 2024*

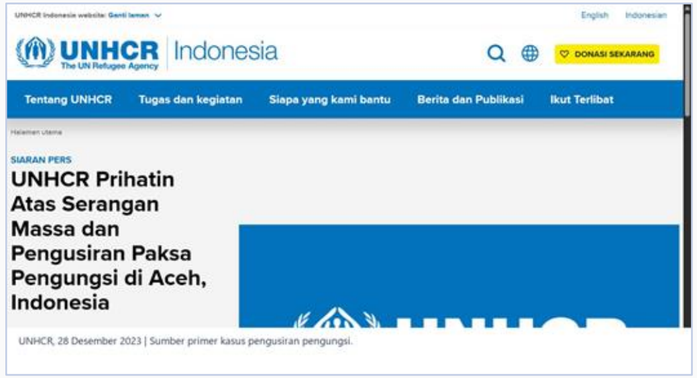
## Status pengungsi

**Narasi bahwa pengungsi Rohingya akan "menjajah" Indonesia, disertai generalisasi perilaku buruk satu etnis.**

*AJI dan UNHCR, Desember 2023*

*Cuplikan dari laporan dan rilis resmi, bukan unggahan asli. Identitas akun dan makian disensor; contoh bukan penetapan bersalah.*

# Dari layar ke jalan










27 Desember 2023, Banda Aceh

## Pengungsi Rohingya

**UNHCR mengaitkan serangan massa dengan kampanye kebencian dan disinformasi daring. 137 pengungsi dipindahkan paksa dari penampungan.**

29-30 Juli 2016, Tanjungbalai

## Kerusuhan SARA

**Menurut kronologi polisi, informasi di Facebook ikut menggerakkan massa; tempat ibadah dirusak. Penyebar provokasi lanjutan di medsos ditangkap.**

Agustus 2019, Surabaya dan Papua

## Rasisme memicu protes

**Tindakan rasis terhadap mahasiswa Papua di Surabaya beredar luas dan memicu gelombang protes di berbagai kota di Papua (Komnas HAM).**

*Peran media sosial berbeda di tiap kasus; satu unggahan jarang menjadi satu-satunya penyebab. Sumber: UNHCR dan AJI (2023); Merdeka, detikNews, ISEAS (2016); KontraS dan Komnas HAM (2019).*

# Seberapa besar masalahnya?

**13,82%**

**dari sekitar 1,45 juta teks yang dipantau AJI-Monash terklasifikasi ujaran kebencian (September 2023 sampai Maret 2024).**

*AJI-Monash, 2024*

**326**

**dari 341 dugaan pelanggaran konten internet temuan Bawaslu hingga awal Februari 2024 dikategorikan ujaran kebencian.**

*Bawaslu RI, 8 Februari 2024*

**718**

**aduan masuk ke program Peringatan Virtual Police Polri sepanjang 2023; 234 di antaranya diblokir.**

*Tribratanews Polri, 27 Desember 2023*

*Satuan dan cakupan tiap angka berbeda, jadi tidak untuk dijumlahkan. Gambar: dashboard pemantauan AJI-Monash dalam laporan 2024.*

# Kritik, kasar, atau kebencian?

## Kritik

Menilai kebijakan, tindakan, atau mutu layanan.

Contoh

*"Pelayanan SKCK lambat, tolong dibenahi."*

Dilindungi sebagai kebebasan berekspresi.

## Bahasa kasar

Makian atau penghinaan tanpa menyerang identitas kelompok.

Contoh

*"Dasar [makian], kerjanya lambat!"*

Bisa melanggar aturan lain, tergantung konteks.

## Ujaran kebencian

Menyerang orang atau kelompok dengan identitasnya: agama, etnis, ras, gender.

Contoh

*"Kelompok [X] itu semua penipu, usir saja!"*

Perlu dicegah, terutama bila berisi ajakan.

**Ujaran kebencian bisa tanpa makian, dan makian belum tentu ujaran kebencian: sasaran dan konteks lebih penting daripada daftar kata.**

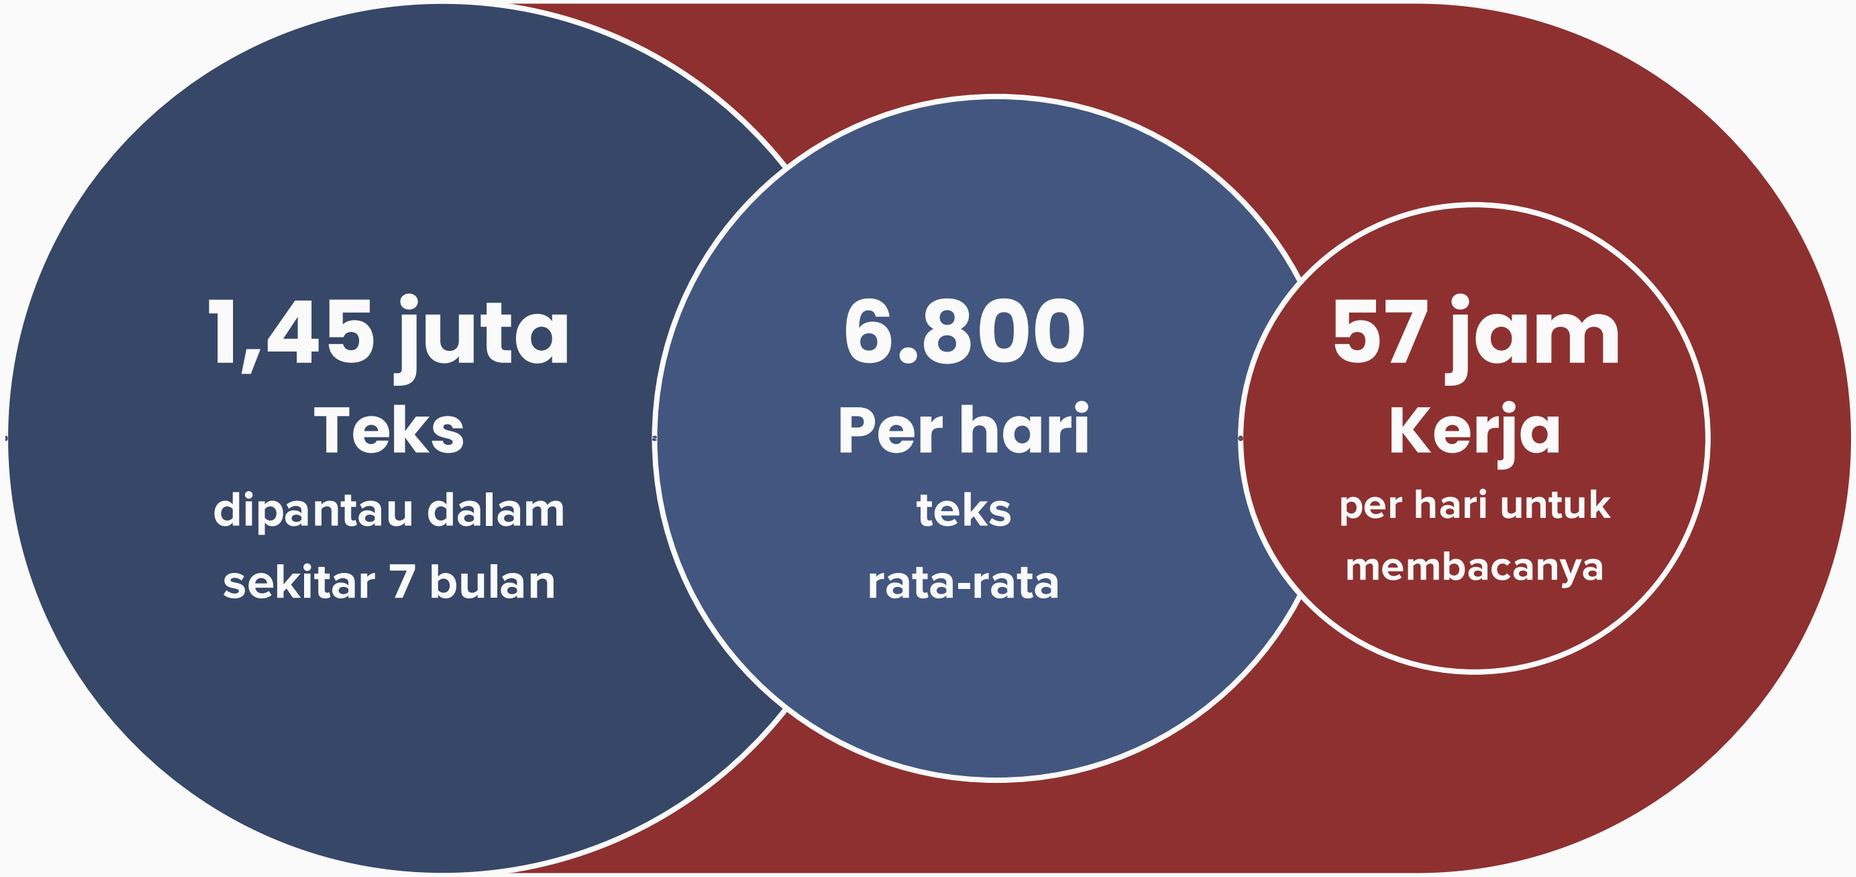
*Rujukan: PBB, Understanding Hate Speech; Ibrohim dan Budi (2019). Contoh disamarkan.*

# Payung hukum

- **UU ITE (UU 1/2024) Pasal 28 ayat 2: hasutan kebencian berbasis identitas; keberlakuannya dibatasi Pasal II seiring berlakunya KUHP baru.**
- **KUHP (UU 1/2023), efektif 2 Januari 2026: Pasal 242-243 (permusuhan terhadap golongan), 246-247 (penghasutan), 300-301 (agama).**
- **UU 1/2026: mengubah Pasal 243 dan 300; Pasal 243 kini memuat unsur akibat timbulnya kekerasan.**
- **SE Kapolri SE/6/X/2015: pedoman penanganan ujaran kebencian yang mengutamakan langkah pencegahan.**

*Ringkasan untuk pembelajaran; penentuan pasal suatu perkara tetap memerlukan pemeriksaan unsur dan waktu perbuatan.*
*Sumber: JDIH Komdigi (UU 1/2024), peraturan.go.id (UU 1/2023), UU 1/2026, SE/6/X/2015.*

# Terlalu banyak untuk dimoderasi




*Hitungan kasar: 1,45 juta teks (September 2023 sampai Maret 2024, sekitar 213 hari) = sekitar 6.800 teks per hari. Jika satu teks dibaca 30 detik, butuh sekitar 57 jam kerja setiap hari.*

# Bagaimana AI membantu?

1
**Pantau**
Konten publik via kata kunci

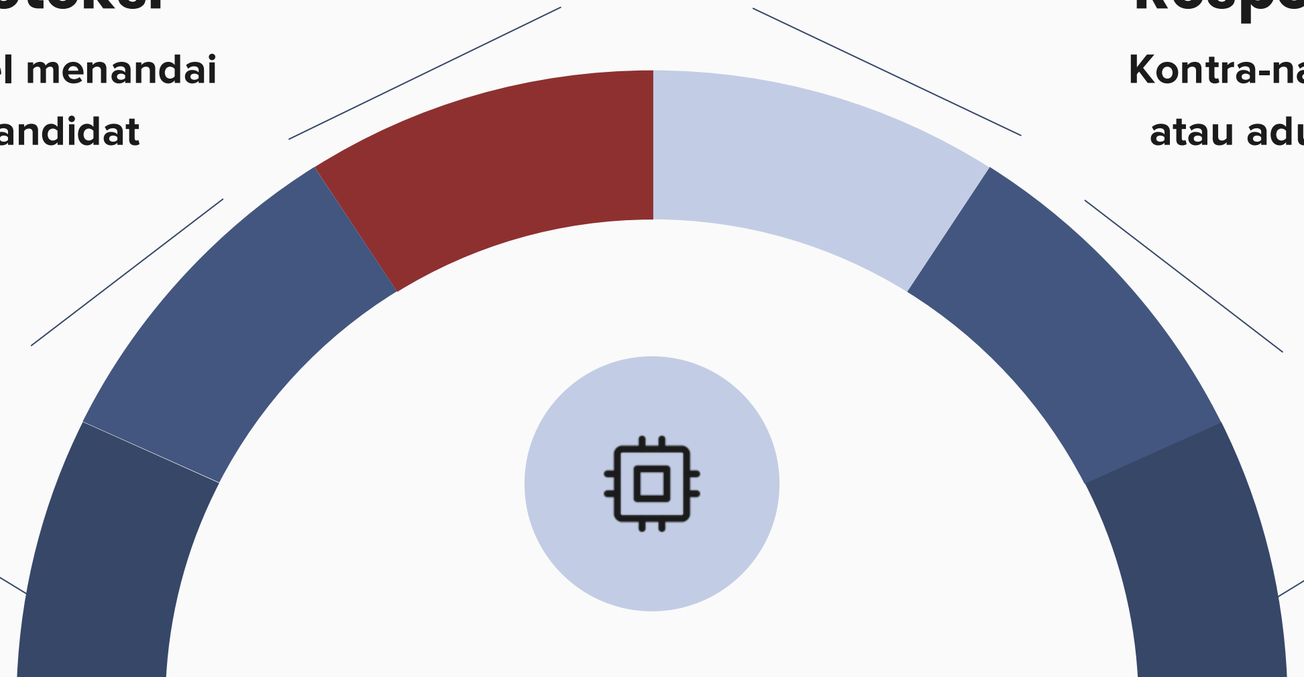
2
**Deteksi**
Model menandai kandidat

3
**Prioritas**
Urutkan dari risiko tertinggi

4
**Verifikasi**
Analis cek konteks

5
**Respons**
Kontra-narasi atau aduan

6
**Evaluasi**
Catat koreksi, perbaiki model



# *Hate Speech Detection*

***Hate speech detection*** **adalah proses otomatis untuk menandai teks yang menyerang orang atau kelompok berdasarkan identitasnya, dan membedakannya dari kritik serta bahasa kasar.**

| | | | |
|---|---|---|---|
| *"Pelayanan SIM di sini lambat, tolong dibenahi."* | → | **Bukan HS** | skor 0,96 |
| *"Dasar [makian], kerjanya cuma main HP!"* | → | **Kasar** | skor 0,88 |
| *"Kelompok [X] itu semua penipu, usir saja!"* | → | **Kebencian** | skor 0,93 |

*Contoh disamarkan dan skor bersifat ilustrasi. Satu teks bisa mendapat lebih dari satu label (multi-label).*

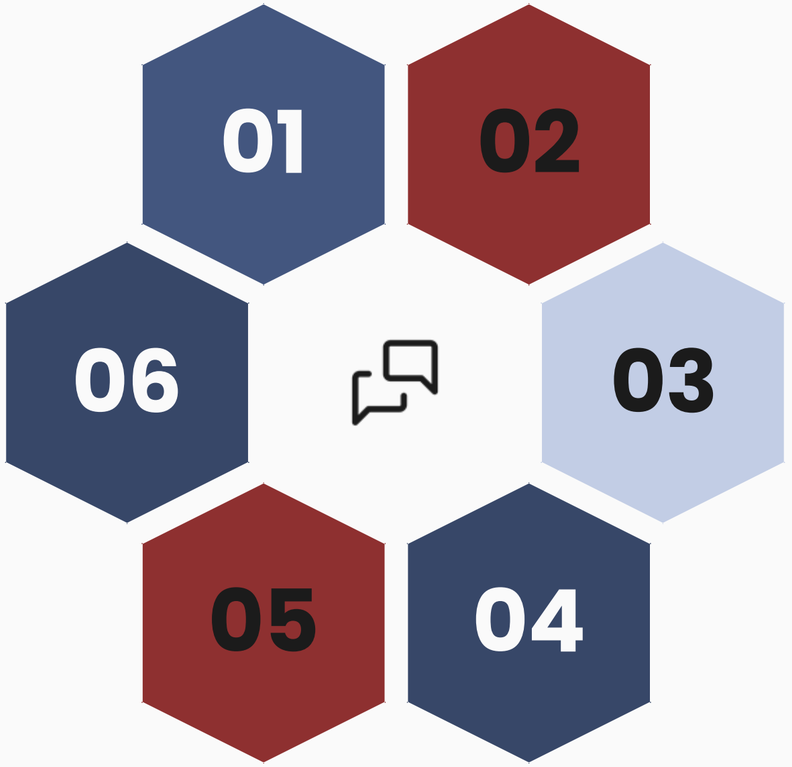
# Dataset Ibrohim dan Budi (2019)

**Ujaran kebencian**

HS: ya atau tidak

**Bahasa kasar**

Abusive: ya atau tidak, terpisah dari HS




**Multi-label**

Satu tweet bisa punya beberapa label sekaligus

**Sasaran**

Individu atau kelompok

**Tingkat**

Lemah, sedang, atau kuat

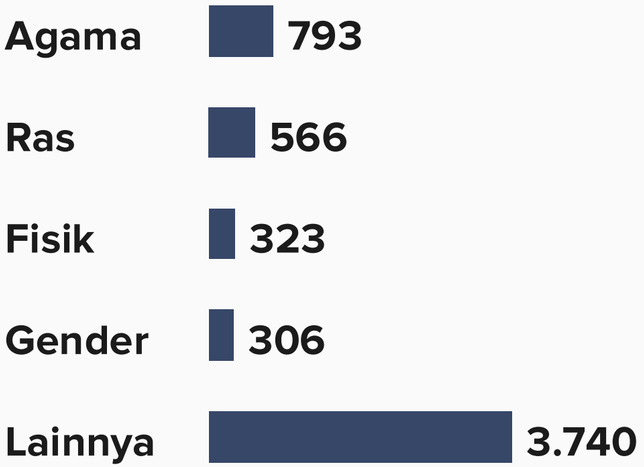
**Kategori**

Agama, ras, fisik, gender, lainnya

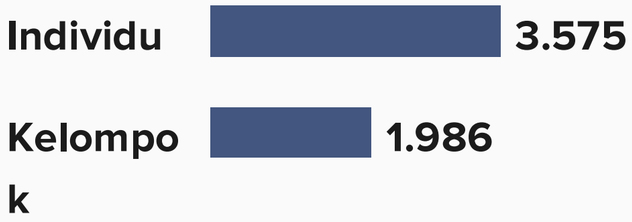
*13.169 tweet berbahasa Indonesia: 5.561 berlabel HS dan 5.043 berlabel kasar. Sumber: Ibrohim dan Budi, ACL ALW3 2019; repositori GitHub penulis.*

# Distribusi label dalam dataset

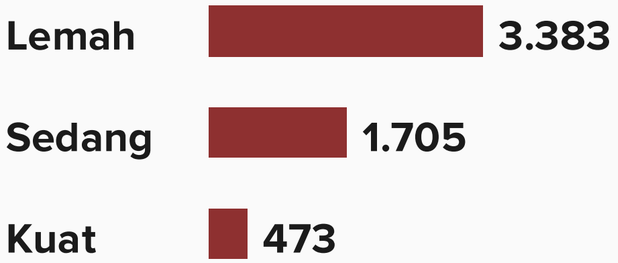
## Kategori




## Sasaran




## Tingkat




**Data tidak seimbang: kategori "lainnya" dan tingkat "lemah" mendominasi, sedangkan kebencian tingkat "kuat" relatif jarang. Ketidakseimbangan ini menjadi tantangan saat melatih model.**

*Hitungan nilai 1 per kolom pada re_dataset.csv (5.561 tweet berlabel HS). Satu tweet bisa memiliki beberapa label. Sumber: github.com/okkyibrohim/id-multi-label-hate-speech-and-abusive-language-detection*

# *How it Works*

## Label

Anotator memberi label pada tiap tweet

## Bersihkan

Rapikan slang dan ejaan yang disamarkan

## Latih

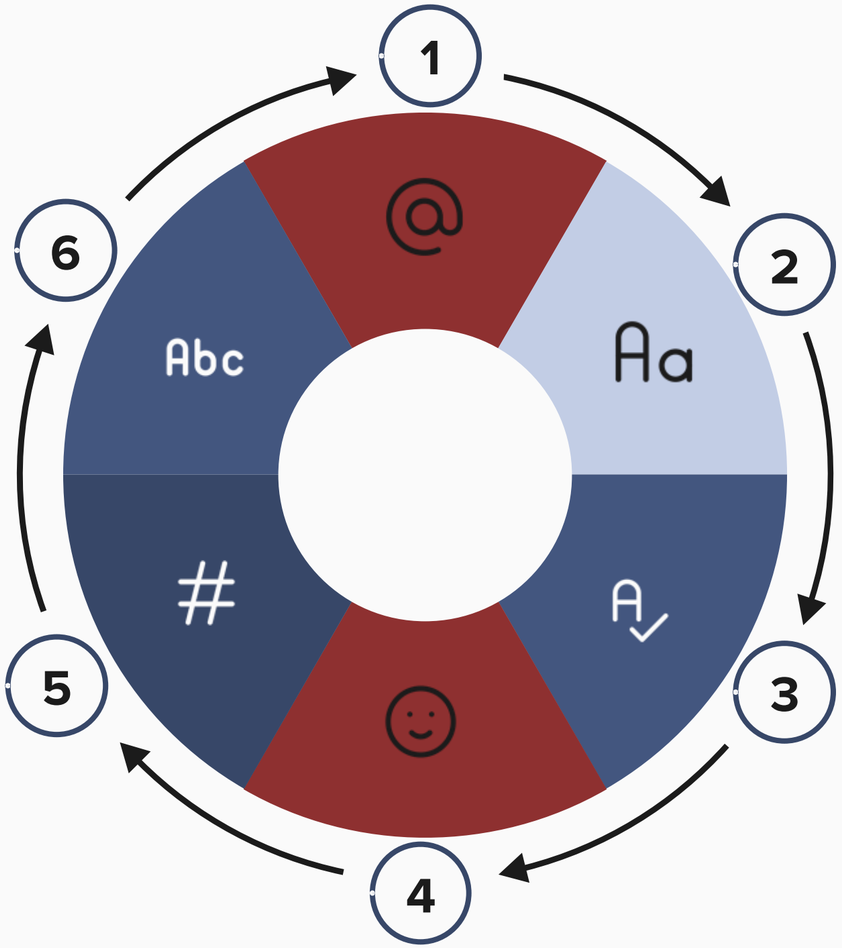
Model multi-label belajar pola dari ribuan contoh

## Prediksi

Tiap label diberi skor; di atas ambang ditandai



# Pra-pemrosesan teks




**01**

Hapus mention dan link

**02**

Ubah ke huruf kecil semua

**03**

Ubah slang: gk jadi tidak

**04**

Emoji diubah jadi kata

**05**

Pecah tagar jadi kata

**06**

Pulihkan ejaan samaran: p3n1pu jadi penipu

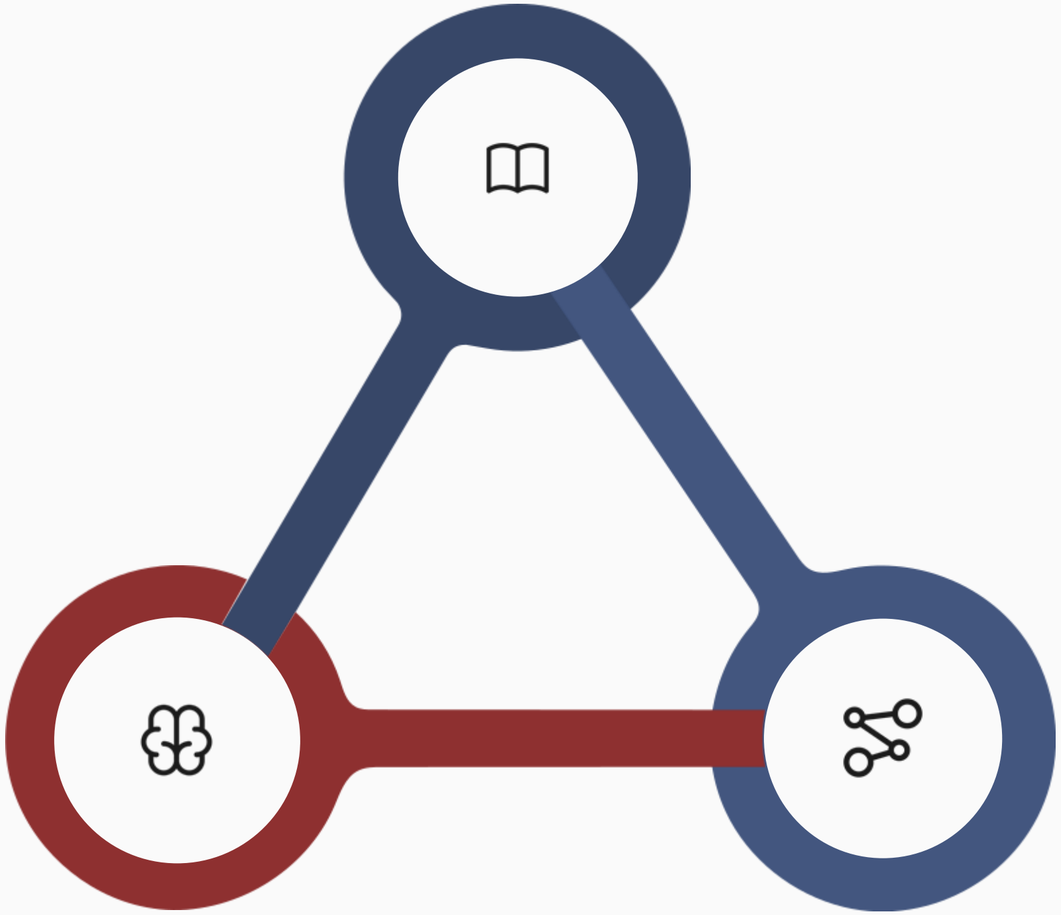
**Sebelum**

@akun_x
DASAR K4MU
S3MUA
P3N1PU!!!
#usirsaja

**Sesudah**

dasar kamu semua penipu usir saja

# Pendekatan *hate speech detection*



## Berbasis kamus

Mencocokkan daftar kata kasar. Cepat, tapi mudah dikelabui ejaan samaran dan buta konteks.

## *Machine learning*

Naive Bayes, SVM, atau Random Forest belajar dari data berlabel.

## Model bahasa

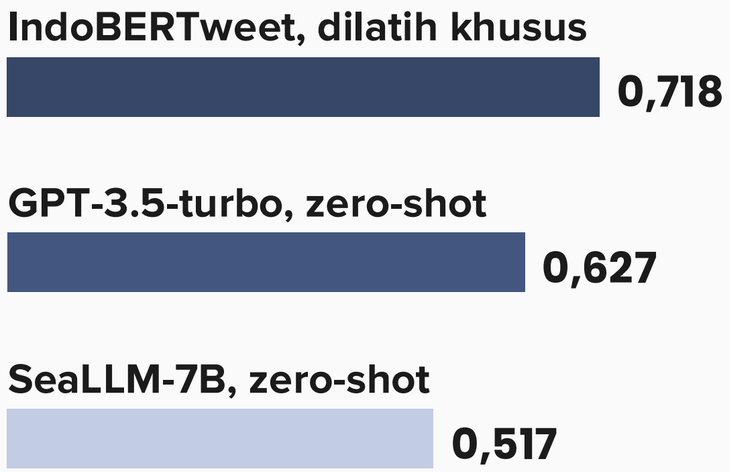
IndoBERT dan IndoBERTweet paham konteks; LLM bisa dipakai lewat prompt tanpa pelatihan khusus.

*Pilihan model tetap butuh data lokal dan evaluasi; model yang lebih besar belum tentu lebih akurat.*

# Model besar belum tentu unggul

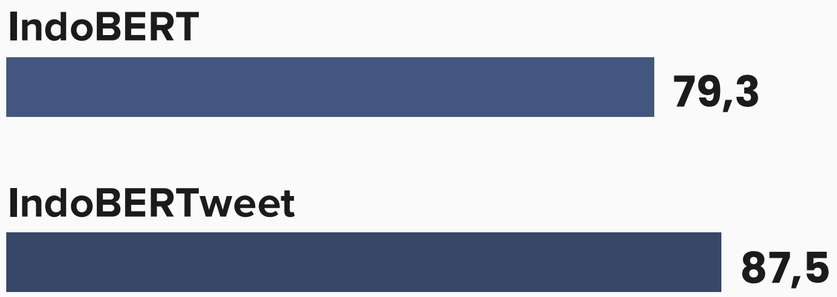
## IndoToxic2024: Macro-F1

Dilatih khusus vs LLM tanpa pelatihan (zero-shot)




## IndoBERTweet (2021): Macro-F1

Deteksi HS pada data Ibrohim dan Budi



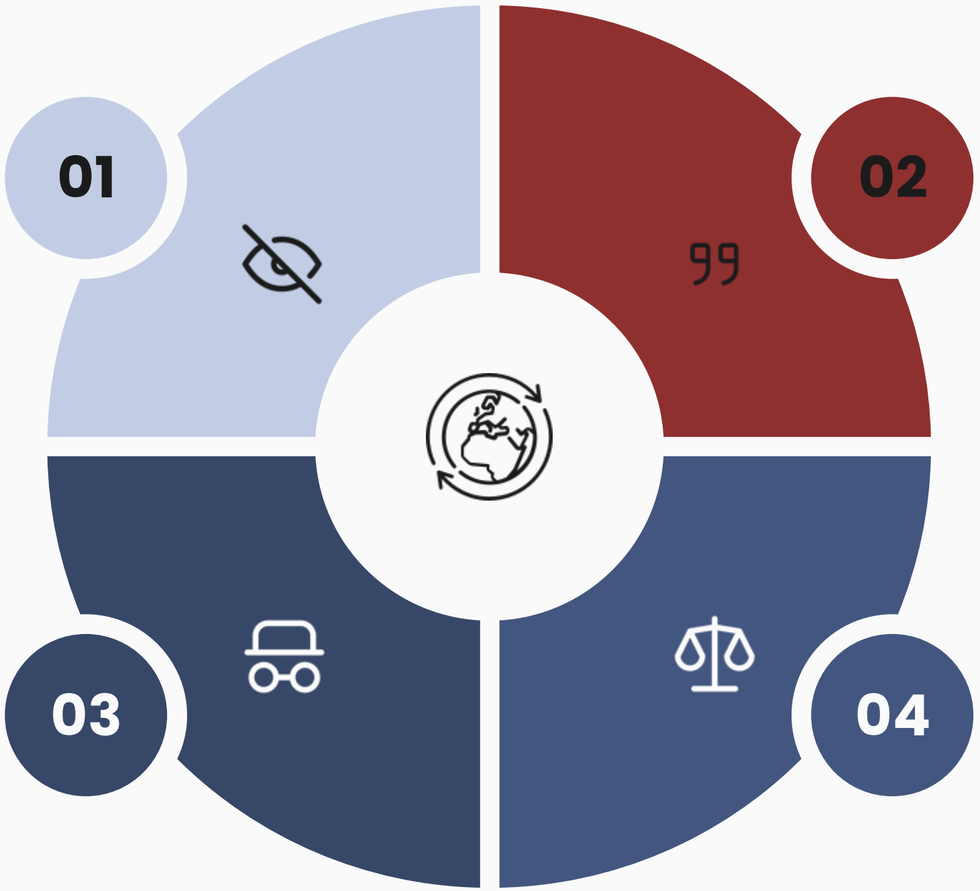

**Pelajaran: model yang dilatih dengan data lokal bisa mengungguli LLM umum. Angka dari dua penelitian berbeda tidak untuk dibandingkan langsung.**

*Sumber: Susanto dkk., IndoToxic2024 (arXiv 2406.19349, Tabel 5a); Koto, Lau, Baldwin, IndoBERTweet (EMNLP 2021).*

# Tantangan yang perlu diwaspadai

## Ejaan samaran

*"p3n1pu"*, *"pe nipu"* Huruf diganti atau dipisah agar lolos filter kata.




## Kutipan

Berita atau kecaman yang mengutip kata kebencian bisa salah ditandai.

## Kode samar

Istilah terselubung (*dog whistle*) yang maknanya hanya dipahami kelompok tertentu dan terus berubah.

## Bias

Model bisa lebih sering salah pada dialek atau kelompok tertentu.

# Dua jenis kesalahan model

| | Model menandai HS | Model tidak menandai |
|---|---|---|
| Sebenarnya HS | **Tepat**<br>Kebencian tertangkap | **Lolos**<br>False negative: kebencian dibiarkan |
| Bukan HS | **Salah tandai**<br>False positive: kritik ikut terbungkam | **Tepat**<br>Teks wajar dibiarkan |

F1-score merangkum precision dan recall. Dalam konteks kepolisian, setiap tanda dari model tetap diverifikasi manusia.

## Precision

Dari semua yang ditandai, berapa yang benar-benar ujaran kebencian?

## Recall

Dari semua ujaran kebencian, berapa yang berhasil ditandai?

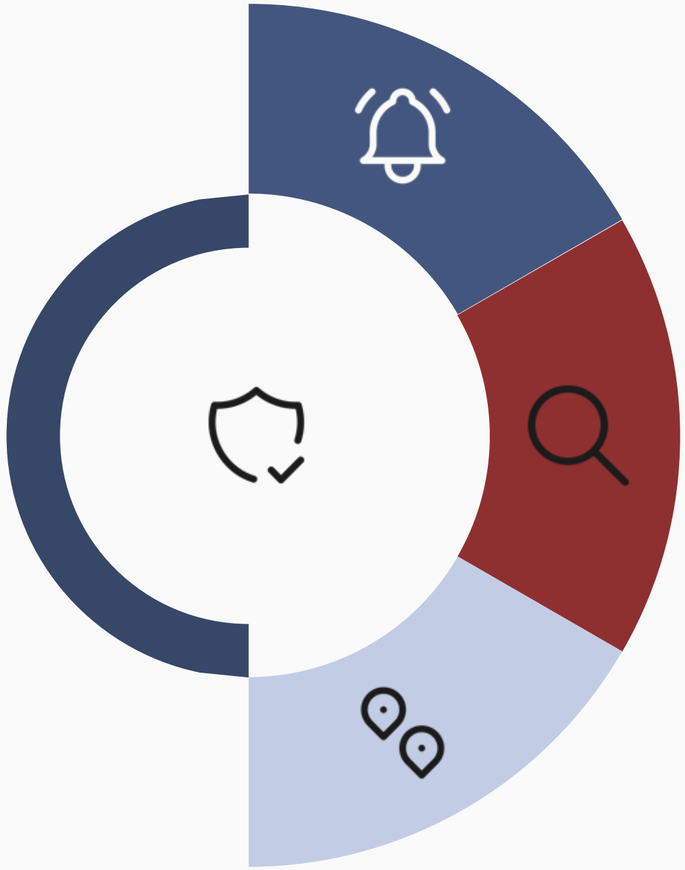
## Ambang skor

Ambang rendah: lebih banyak tertangkap, tapi kritik berisiko terbungkam. Ambang tinggi: kritik lebih aman, tapi lebih banyak yang lolos.

# Peringatan dini konflik

## Tujuannya

**Membaca sinyal lonjakan kebencian lebih awal, bukan meramal kerusuhan secara pasti.**



## Pantau tren

**Lonjakan kebencian terhadap kelompok tertentu pada suatu isu atau wilayah.**

## Baca konteks

**Lonjakan bisa berasal dari berita, kampanye antirasisme, atau bot.**

## Cek lapangan

**Padukan dengan informasi lapangan sebelum memilih respons.**

*Contoh nyata: dashboard AJI-Monash (Pemilu 2024), CSIS National Hate Speech Dashboard, dan UNDP eMonitor+. Belum ada evaluasi terbuka bahwa dashboard tertentu menurunkan kerusuhan.*

# Alur *human-in-the-loop*

## Deteksi

Model menandai konten yang berisiko

## Verifikasi

Analis cek sasaran, konteks, dan ajakan




## Evaluasi

Catat koreksi untuk memperbaiki model

## Respons

Kontra-narasi, aduan ke platform, hukum sebagai jalan terakhir

# Moderasi AI di platform

**66,4%**

konten hateful conduct (1,5 juta ditindak) ditemukan sebelum dilaporkan pengguna.

*Meta, April-Juni 2026*

**98,7%**

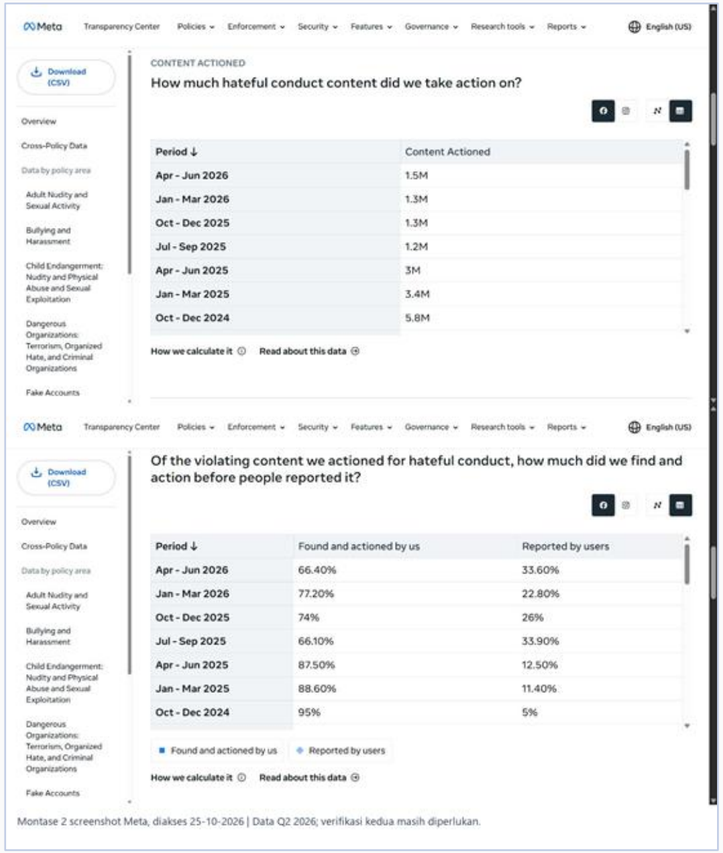
video kebencian dihapus secara proaktif secara global; untuk Indonesia 98,3%.

*TikTok, April-Juni 2026*

**155.391**

video kategori hateful or abusive dihapus (kategori lebih luas dari ujaran kebencian).

*YouTube, April-Juni 2026*




Montase 2 screenshot Meta, diakses 25-10-2026 | Data Q2 2026; verifikasi kedua masih diperlukan.

*Proaktif berarti ditindak sebelum dilaporkan, bukan ukuran akurasi. Data laporan transparansi tiap platform (sumber tunggal); definisi kategori berbeda sehingga tidak untuk diperingkat.*

# Penerapan di Indonesia

- **Virtual Police (sejak Februari 2021): peringatan lewat pesan langsung sebagai langkah pencegahan; sepanjang 2023 tercatat 718 aduan.**
- **Dashboard AJI-Monash (Pemilu 2024): klasifikasi otomatis 1,45 juta teks tentang kelompok rentan, dipaparkan kepada Bawaslu.**
- **CSIS National Hate Speech Dashboard: memantau ujaran kebencian terhadap kelompok minoritas di Twitter/X.**
- **Komdigi, aduankonten.id: masyarakat melapor dengan tautan atau tangkapan layar, lalu diverifikasi dan ditindaklanjuti bersama platform.**

*Sumber: Tribratanews Polri (2021, 2023); AJI-Monash (2024); CSIS Indonesia; Komdigi (10 Maret 2025).*

# Etika dan batasan

1 **Ekspresi**
Kritik bukan ujaran kebencian

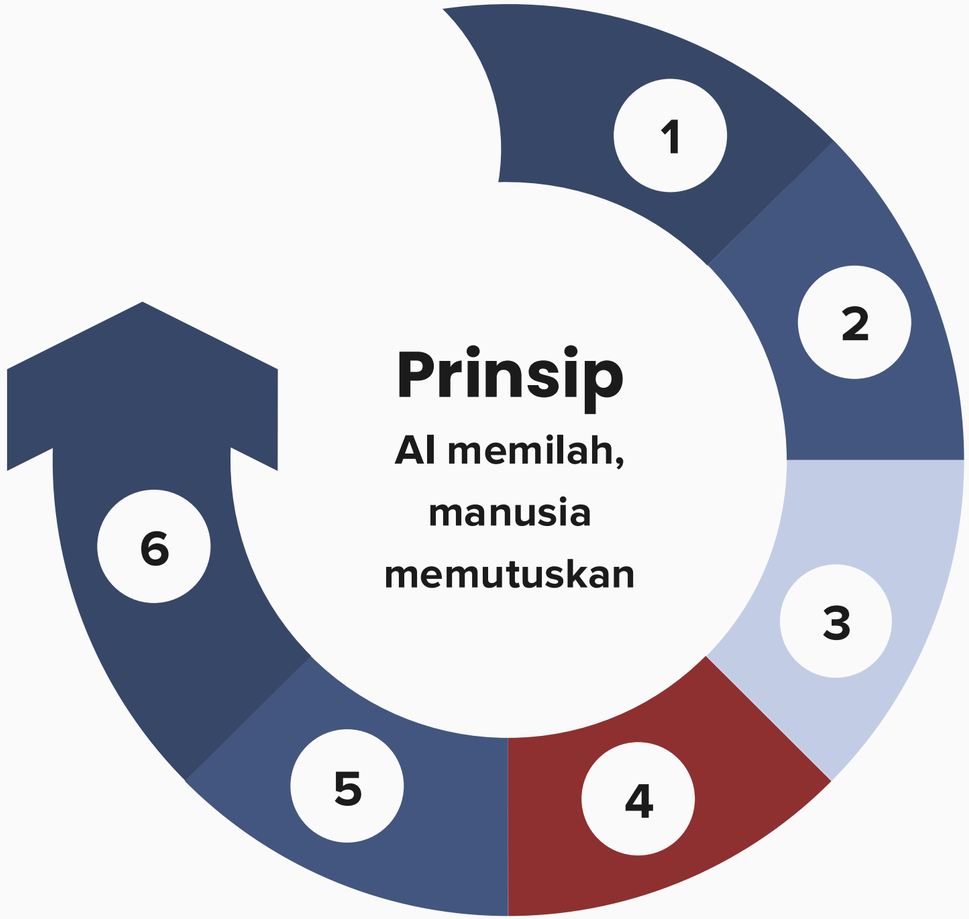
2 **Bias**
Model bisa bias pada dialek tertentu

3 **Konteks**
Skor AI bukan bukti unsur pidana

4 **Audit**
Catat sumber, versi model, alasan

5 **Privasi**
Kumpulkan data seperlunya

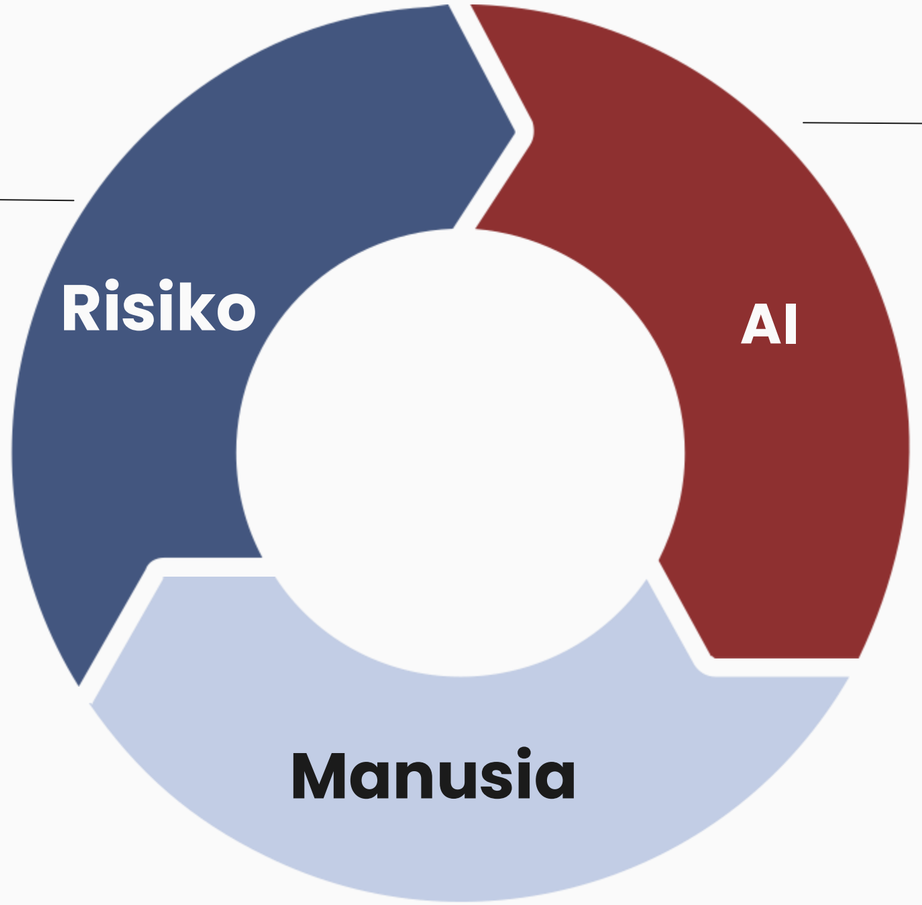
6 **Koreksi**
Sediakan jalur banding



# Kesimpulan

## Risiko

Ujaran kebencian di ruang digital dapat ikut memperburuk konflik di dunia nyata.




## AI

*Hate speech detection* membantu memilah jutaan konten dan memberi sinyal lebih awal.

## Manusia

Keputusan tetap di tangan manusia, dengan memperhatikan konteks, hukum, dan kebebasan berekspresi.

# Terima kasih

**Muhammad Okky Ibrohim, S.Mat., M.Kom., Ph.D.**

**Fakultas Ilmu Komputer, Universitas Indonesia**